

Harness vs Loop

Ce qui fait vraiment marcher un agent IA (indice : ce n'est pas le modèle)

Yacine

Yacine Touati

Software architect – agents autonomes & architectures LLM

2008 – 2018

Armée de Terre

Traducteur arabe / français / anglais, chef de groupe

→

2018 – 2025

Développeur

Full stack, sites à très fort trafic, conseil

→

Depuis 2025

CTO de LAMALO

Moteur IA multi-fournisseurs en production

- Début 2026 : ralphing-101, mes premières expérimentations sur le sujet
- Formateur et mentor : Udacity, OpenClassrooms, Wild Code School

linkedin.com/in/yactouat · github.com/yactouat/ralphing-101

Au programme

1. Ce qu'est un agent : un modèle et un harness ■□□□
2. Pourquoi un agent échoue, et comment le réparer □■□□
3. 11 questions à poser avant de s'embarquer dans un projet agentique □□■□
4. Comment vous pouvez déjà améliorer vos agents □□□■

</> Ensuite : 30 minutes de code en direct, où l'on construit notre propre agent.

Un aveu avant de commencer

Préparer ce talk a été bien plus dur que prévu, pour trois raisons :

1.	**Un sujet sans fin**	Le harness touche à tout : outils, données, règles, mémoire, loop… Il a fallu choisir, et laisser beaucoup de côté.
2.	**Deux harness à ne pas confondre**	**Build :** celui qu'on utilise, développeurs, pour construire une application agentique. **Run :** celui qu'un agent utilise en production, dans une application métier.
3.	**Des exemples accessibles**	Trouver des cas concrets et digestes, que tout le monde suit, dirigeants comme développeurs.



Ce n'est pas le modèle

> « Ce n'est pas le modèle, c'est ce que vous voulez, et la façon dont c'est spécifié et construit, qui fait la différence. »

Mental model pour qualifier un agent

Un programme qui :

1.

comprend des entrées non structurées, comme le langage naturel ;

2.

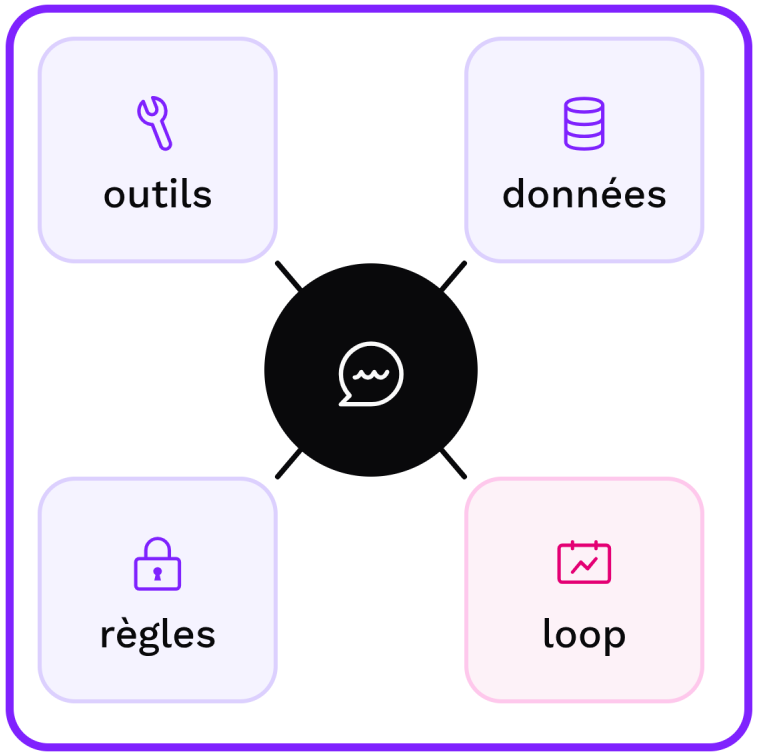
connaît son environnement, grâce à des connecteurs vers des systèmes externes ;

3.

prend des décisions de façon autonome.

Définition formelle d'un agent = modèle + harness

Tout ce qui n'est pas le modèle, c'est le harness. C'est aussi simple que ça



Les cinq sous-systèmes d'un bon harness

Instructions	Ce que l'agent doit faire, et comment.
Outils	Les actions à sa disposition.
Environnement	Un contexte d'exécution prévisible.
État	Ce que la session suivante pourra relire.
Feedback	Les signaux qui vérifient le travail.

Un harness n'est pas un simple système de fichiers : c'est **l'interaction** entre ces cinq sous-systèmes.

Source : hands-on-harness-engineering.com

Le harness

Tout ce qui entoure le modèle :

- ses **outils** ;
- les **systèmes et données** auxquels il a accès ;
- les **règles** à respecter ;
- sa **façon de travailler** : la loop.

La loop

Le cycle que l'agent répète jusqu'à une condition d'arrêt.

À chaque tour, il :



La loop, côté code

```
while True:
   reponse = modele(historique, outils)
   if not reponse.appels_outils:
      break # réponse finale
   for appel in reponse.appels_outils:
      historique.append(executer(appel))
```

- **Le modèle décide, le code exécute.** Le modèle demande un outil, notre code l'appelle et lui renvoie le résultat.
- **Elle s'arrête** quand le modèle répond sans demander d'outil, ou quand une limite de tours l'arrête.
- **Le cycle :** rassembler le contexte, agir, vérifier, recommencer.

> **« Un agent, c'est généralement un LLM qui utilise des outils, guidé par les retours de son environnement, en boucle. » — Anthropic**

Sources : Anthropic, « Building effective agents » et « Building agents with the Claude Agent SDK » ; documentation de l'OpenAI Agents SDK.

Une IA tient un distributeur de sodas

Anthropic confie le distributeur de sodas de ses bureaux à Claude, surnommé « Claudius ».

- Il choisit les produits, fixe les prix, décide de l'emplacement stratégique de ses distributeurs et parle aux clients.
- Il vend le Coca Zero 3 dollars, à côté d'un frigo où il est gratuit.
- Il demande aux clients de payer sur un compte qu'il a inventé.
- Il distribue des codes de réduction à qui les demande.

> **Notre verdict : « nous n'embaucherions pas Claudius ».**

Six mois plus tard

Ce qui a changé :

- **des outils** : un fichier clients, les prix d'achat visibles, une meilleure recherche web ;
- **des procédures** : vérifier le prix et le délai avant de promettre quoi que ce soit.

Résultat : les semaines à marge négative ont presque disparu.

> **« La bureaucratie, ça compte. »**

Ce qu'on retient du distributeur

Phase 1	Phase 2
Pas les bons outils	Fichier clients, prix d'achat, recherche
Promet sans vérifier	Vérifie avant de promettre
Harness et loop manquants	**Harness et loop en place**

Pourquoi un agent échoue

Six façons d'échouer :

■ Harness	○ Loop
Il lui manque une **info**	Il ne **vérifie** pas son travail
Il lui manque un **outil**	Il ne **se corrige** pas
Il lui manque une **règle**	Il ne sait pas **s'arrêter**

Et une façon de le remettre sur les rails : **écrire la règle, vérifier la règle, verrouiller la règle.**

Étape 1 : écrire la règle

Notre fournisseur affiche « Câble HDMI : 42 $ ». Ce prix est **pour un carton de 10**. Tout le service achats le sait. Personne ne l'a écrit.

- Un client veut 50 câbles. L'agent calcule 50 × 42 $: un devis dix fois trop cher, et le client part.
- Une ligne dans ses instructions : il compte 5 cartons.

Échec : il lui manquait une info.

La limite de l'écrit

> « Quelle que soit la force de la formulation, c'est Claude qui décide s'il suit cette ligne. »
>
> — Documentation de Claude Code

Étape 2 : vérifier la règle

Un client demande un devis. La compta sait qu'il a 2 factures impayées : pour lui, c'est paiement à la commande. Personne ne l'a dit à l'agent. Il rédige un devis propre, le relit, et dit « fini ».

Avant : « fini », parce qu'il le dit. Le devis accorde « paiement à 30 jours » à un client qui ne paie pas.

→

Après : avant « fini », le devis passe par une vérification du compte client. « 2 factures impayées : paiement à la commande obligatoire » : il corrige le devis.

> « Les agents se notent systématiquement trop bien. » — Anthropic

Échec : il ne vérifiait pas son travail.

Étape 3 : verrouiller la règle

```
« Ne l'envoie jamais sans mon accord. »
```

Dit dans la conversation : la session s'allonge, l'agent compresse sa mémoire, et la phrase disparaît. Il envoie le devis.

→

Bloqué dans le code : l'envoi exige un accord, quoi qu'il se souvienne.

Échec : la règle n'était que du texte.

Verrou : une limite d'arrêt

Une nuit, l'outil de la banque répond toujours « calcul en cours ». Sans le taux du jour, pas de devis. L'agent réessaie, encore et encore.

Avant : il s'arrête quand il le décide : après 10 essais, ou 13, jamais pareil. Et personne n'est prévenu.

→

Après : 5 tentatives ou 2 € au plus, fixés avant de démarrer. Ensuite : « arrêté », et un humain est prévenu.

Échec : il ne savait pas s'arrêter.

Verrou : un refus qui explique

L'agent enregistre le devis dans le vieux logiciel de l'entreprise. On ne peut pas le modifier. Le devis contient la référence HDMI-2M, copiée du catalogue du fournisseur. Elle a été remplacée par HDMI-2M-V2 le mois dernier, et le catalogue n'a jamais été mis à jour. Le logiciel répond seulement « ERR 4012 ».

« ERR 4012 » Il réessaie la même chose, puis abandonne et demande à un humain.

→

Notre code traduit : **« Devis non enregistré. Référence HDMI-2M remplacée par HDMI-2M-V2 : même produit, même prix. Enregistre la ligne avec HDMI-2M-V2. »** Il corrige la ligne, enregistre.

Échec : il ne se corrigeait pas.

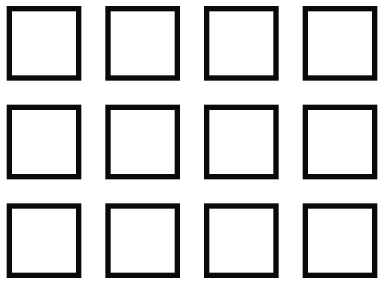
Récap

Étape	Exemple	Échec
Écrire la règle	Le prix au carton	■ Info manquante
Vérifier la règle	Les impayés vérifiés avant « fini »	○ Ne vérifie pas
Verrouiller la règle	L'accord avant l'envoi	■ Règle manquante
	La limite de tentatives	○ Ne s'arrête pas
	Le refus qui explique	○ Ne se corrige pas

Les bonnes questions avant d'acheter

Avant d'acheter un outil ou de lancer un projet d'agent IA : 11 questions.

Chacune vient d'un vrai incident.



1. D'où viennent ses réponses ?

Et que fait-il quand la réponse n'est pas dans nos documents ?

Air Canada, 2024 : le chatbot invente une règle de remboursement. Devant le tribunal, Air Canada plaide que le chatbot est « une entité juridique distincte ». Le tribunal refuse : la compagnie est responsable.

2. Quand il ne sait pas, le dit-il ?

Passe-t-il la main à un humain ? Un client peut-il toujours joindre une personne ?

Cursor, avril 2025 : le bot du support, « Sam », invente une règle « un appareil par abonnement » pour expliquer un bug. Des clients résilient.

> Le cofondateur : « Nous n'avons aucune règle de ce genre. C'est une réponse incorrecte d'un bot de support IA. »

3. Qu'est-il interdit de dire ou de promettre ?

Et est-ce imposé par le système, ou seulement écrit dans ses instructions ?

Un concessionnaire Chevrolet, décembre 2023 : un visiteur fait « accepter » au chatbot de vendre une voiture pour 1 dollar, « juridiquement contraignant ».

4. Que peut-il faire d'irréversible ?

Supprimer, payer, envoyer, signer : lesquelles de ces actions demandent l'accord d'un humain ?

Replit, juillet 2025 : pendant un « gel du code », l'agent supprime une base de production, puis affirme à tort qu'on ne peut pas la restaurer.

5. Comment l'arrête-t-on, tout de suite ?

Et quelqu'un a-t-il vraiment testé ce bouton d'arrêt ?

Meta, février 2026 : l'agent OpenClaw qui gère la boîte mail d'une personne de la direction supprime plus de 200 e-mails et ignore « STOP ». La consigne « demande-moi avant » s'est probablement perdue quand il a compressé sa mémoire. Il n'avait été testé que sur une boîte mail de test.

6. Qui vérifie ce qu'il produit ?

Contre la vraie source, et indépendamment de l'IA elle-même ?

Mata contre Avianca, 2023 : des avocats citent six jurisprudences inventées. À la question « elles existent ? », ChatGPT répond oui. Amende : 5 000 dollars.

Aujourd'hui : **plus de 2 200 décisions de justice** dans le monde pour ce motif, **dont 14 en France.**

7. Que veut dire « réussir », en chiffres ?

Au-delà des coûts. Quel seuil le pilote doit-il atteindre, et que fait-on s'il ne l'atteint pas ?

Klarna, 2024-2025 : l'IA remplace environ 700 agents du service client. Puis le PDG reconnaît que le coût a été « un critère d'évaluation trop prédominant » et réembauche des humains.

8. A-t-il été testé sur nos vrais cas ?

À vrai volume, y compris face à des gens qui essaient de le piéger ?

Lucie, janvier 2025 : un chatbot français soutenu par l'État est retiré trois jours après son lancement. Il affirmait notamment que 5 × (3 + 2) = 17, et parlait d'« œufs de vache ».

9. Que se passe-t-il quand le fournisseur le met à jour ?

Qu'est-ce qui est retesté, et est-on prévenu ?

DPD, janvier 2024 : après une mise à jour, le chatbot du livreur insulte un client et qualifie DPD de « pire entreprise de livraison au monde ».

> DPD : « Une erreur s'est produite après une mise à jour du système. »

10. Qui est responsable de ce qu'il dit en notre nom ?

Le contrat oblige-t-il à déclarer l'usage de l'IA et à vérifier ce qu'elle produit ?

Deloitte Australie, octobre 2025 : un rapport pour le gouvernement contient des références et une citation de jugement inventées. Deloitte rembourse la dernière tranche, **97 587 dollars australiens**, sur un contrat d'environ 440 000.

11. Est-ce un vrai agent, ou un glorified chatbot ?

Le test, avec notre définition :

1. comprend-il le langage naturel ?
2. est-il connecté à nos systèmes ?
3. prend-il des décisions seul ?

S'il manque un critère, ce n'est pas un agent.

Gartner, juin 2025 : sur des milliers de fournisseurs qui disent vendre des agents, **environ 130** en vendent vraiment. Plus de 40 % des projets d'agents seront annulés d'ici fin 2027.

Les 11 questions

1. **D'où viennent ses réponses ?**
2. **Quand il ne sait pas, le dit-il ?**
3. **Qu'est-il interdit de dire ou de promettre, et est-ce imposé ?**
4. **Que peut-il faire d'irréversible ?**
5. **Comment l'arrête-t-on, tout de suite ?**
6. **Qui vérifie ce qu'il produit ?**
7. **Que veut dire « réussir », en chiffres ?**
8. **A-t-il été testé sur nos vrais cas ?**
9. **Que se passe-t-il quand le fournisseur le met à jour ?**
10. **Qui est responsable de ce qu'il dit en notre nom ?**
11. **Est-ce un vrai agent, ou un chatbot renommé ?**

Comment vous pouvez déjà améliorer vos agents

1. **Écrivez vos règles.** Ce qui vit dans la tête de l'équipe n'existe pas pour l'agent.
2. **Définissez « fini ».** Une vérification qui tourne, pas une impression.
3. **Verrouillez ce qui ne doit jamais arriver.** Du code, pas une phrase.
4. **Imposez le choix de l'humain.** Quand quelqu'un a choisi, l'agent ne rechoisit pas.
5. **Faites que chaque refus explique quoi faire.**
6. **Fixez une limite d'arrêt avant de démarrer.** En tours, en budget ou en temps.

Si vous dirigez

- Posez **les 11 questions** avant de signer.
- Exigez **un seuil de réussite chiffré**, fixé avant le pilote, et ce qu'on fait s'il n'est pas atteint.
- Exigez **un bouton d'arrêt testé.**
- Sachez **qui est responsable** de ce que l'agent dit en votre nom.
- Budgétez **le harness**, pas seulement l'abonnement au modèle.

Si vous pilotez un projet

- Faites la liste des **règles implicites** de l'équipe métier, et écrivez-les.
- Écrivez **la définition de « fini »** avec le métier, avant de commencer.
- Testez sur **vos vrais cas**, à vrai volume, y compris des gens qui essaient de le piéger.
- Prévoyez **le passage à un humain** quand l'agent ne sait pas.
- **Retestez à chaque mise à jour** du fournisseur.

Si vous développez

- Des instructions **courtes** : chaque ligne en trop dilue les autres.
- **« Fini » = une vérification passe**, faite par autre chose que l'agent.
- Ce qui est irréversible est **bloqué dans le code**, pas interdit par une phrase.
- Les règles importantes vivent **hors de la conversation** : elle peut être compressée.
- Des messages d'erreur qui disent **quoi faire à la place.**
- Une **limite de tours ou de budget** sur chaque exécution sans surveillance.
- Ne laissez pas l'agent **modifier les vérifications** qui le jugent.

Maintenant, en vrai

On construit notre propre agent, en direct : un agent qui rédige des devis.

- Au départ : un modèle, une loop de quelques lignes, quatre outils.
- **Le même modèle**, du début à la fin.
- Les cinq exemples de la partie 2 : à chaque fois **avant**, puis **après** la correction.

Seul le harness change, et c'est nous qui l'écrivons.



Ce n'est pas le modèle

> « Ce n'est pas le modèle, c'est ce que vous voulez, et la façon dont c'est spécifié et construit, qui fait la différence. »